

2026 AIC 噪声标签细粒度识别赛：比赛判断与团队交接报告

横纵分析法深度研究报告

研究时间：2026-08-16 | 所属领域：鲁棒微调、细粒度图像分类、竞赛工程 | 研究对象类型：算法挑战赛与在研项目

Codex / 项目组 · 2026-08-16

目录

一、一句话定义	4
二、先给判断：应该怎么传	4
三、纵向分析：这场比赛如何把问题一步步推向「可迁移系统」	4
3.1 赛题的起点不是模型，而是约束	4
3.2 四阶段赛制改变了优化目标	5
3.3 项目第一阶段：从能跑到 76 分平台	5
3.4 第二阶段：cleanlab、mixup 和同轨迹 SWA	5
3.5 第三阶段：推理杠杆和打榜系统的成熟	6
3.6 第四阶段：位置编码重采样把上限推到 78.91	6
3.7 第五阶段：后续创新大多证明「复杂不等于更强」	7
四、横向分析：四种交接方式，谁适合这个项目	7
4.1 直接把整个目录压缩发过去	7
4.2 继续使用现有公开 GitHub 仓库	7
4.3 新建私有仓库，使用 Git LFS	8
4.4 私有仓库 + GitHub Release 资产	8
4.5 最终选择	8
五、交给队友的「精华」到底是什么	8
5.1 第一层：决策压缩	8
5.2 第二层：一个能跑的参考模型	9
5.3 第三层：实验账本，而不是日志墓地	9

5.4 第四层：自动打榜的安全机制	9
5.5 第五层：负结果的边界	9
六、接手后的前 72 小时	10
第 0–4 小时：建立信任链	10
第 4–12 小时：复现推理	10
第 12–24 小时：复现训练烟测	10
第 24–48 小时：部署只读打榜	10
第 48–72 小时：第一发受控提交	10
七、复赛与半决赛策略：哪些初赛结论可带走	10
可以直接带走	10
必须重新验证	10
应新增的对照	11
八、纵横交汇：历史如何塑造了今天的竞争位置	11
九、三个未来剧本	11
最可能剧本：基准迁移成功，分数由数据适配决定	11
最危险剧本：把初赛 78.91 当固定配方，过拟合旧阶段经验	12
最乐观剧本：交接系统反过来提升研究速度	12
十、最终行动清单	12
十一、信息来源	12
十二、方法论说明	13

一、一句话定义

这不是一场「把初赛 checkpoint 发给队友就算交接」的比赛，而是一条会在复赛、半决赛连续更换数据规模和分布、最终要求代码复现与线下答辩的鲁棒微调长链路；真正有价值的资产，是一套能随阶段迁移的方法、证据和安全打榜系统。

二、先给判断：应该怎么传

建议采用「私有 Git 仓库 + 私有 Release 大文件 + SHA-256 清单」的两层交接。

私有 Git 仓库保存代码、配置、实验结论、自动打榜控制面、复现说明、测试和 provenance；750 MB 左右的 checkpoint 不进入普通 Git 历史，单独作为私有 Release 资产上传。现有公开仓库 [WRw5w/lihao](#) 不再继续承担竞赛交接，因为公开性与赛事数据、提交产物和仍在演进的策略并不相容。

交付模型也不能只写「最高 78.9122」。本地证据里应同时保留三种口径：

历史最高合法单次	b512_aligned	78.9122	否：本地没有找到——绑定 checkpoint
当前最佳交付参考	b448_aligned formal v2	78.8561	是：模型、日志、预测、provenance 完整
可靠重训基准	champion_real	78.5477	是：用来估计 run variance

这三个数字并不矛盾。78.9122 说明路线的上限；78.8561 是能交到队友手上的实物；78.5477 提醒团队，单次峰值不是稳定复现分。

自动打榜机也应该传，但不能把浏览器 profile、cookie 和旧队列一起打包。应该传的是受控状态机源码、调用契约、测试、helper 的固定哈希和机器配置清单。队友在自己的机器上重新登录 AICOMP，先跑 fake-only 和只读检查，再由队长授权第一发真实提交。

三、纵向分析：这场比赛如何把问题一步步推向「可迁移系统」

3.1 赛题的起点不是模型，而是约束

官方在 2026 年 4 月 30 日发布赛题。任务看起来像一个常规的 500 类自然动植物细粒度分类：训练集来自互联网、标签有噪声，测试集由人工精确标注，最终看 Top-1 Accuracy。但约束一加上去，问题的形状立刻变了。

骨干只能使用 OpenAI 官方 CLIP ViT-B/32；不能换更大视觉模型，不能调用闭源视觉 API，不能引入额外数据，测试集不能参与训练。允许的是 Prompt Tuning、Adapter、LoRA、鲁棒损失、噪声过滤、伪标签和表征约束。最终方案必须是单模型或单一推理流程，不能做多模型融合或投票。进入半决赛后还要提交完整训练、验证、推理脚本、环境说明、可执行模型或容器、技术方案 PDF；总决赛代码若无法复现，成绩可能被取消。完整约束见 [AIC 官方赛题页](#)。

这组约束决定了一个关键事实：模型容量不是可以无限扩张的轴，项目必须在「冻结的有限骨干」「错误监督」「不同阶段的数据变化」之间找平衡。比赛不是在问谁能找到更大的 backbone，而是在问谁能把一个固定 backbone 驯服得更稳。

CLIP 本身来自 2021 年的自然语言监督预训练。原论文用 4 亿图文对训练可迁移视觉表示，并展示了在多个细粒度分类数据集上的零样本迁移能力；这解释了为什么赛事方选它作为共同起点，也解释了为什么灾难性遗忘会成为核心风险。[CLIP 论文](#)

LoRA 则提供了另一块拼图：冻结预训练权重，在 Transformer 层中注入低秩更新矩阵，用更少的可训练参数完成任务适配。[LoRA 论文](#) 在这道题里，LoRA 不只是省显存，它还天然形成了一道「别让脏标签把预训练表示改坏」的结构性护栏。

3.2 四阶段赛制改变了优化目标

官方规则把线上部分分为初赛、复赛、半决赛，再进入线下总决赛：

	线上人数	线上训练集	线上验证集	线上赛制	线上赛制
初赛	500	103,218	24,967	标签噪声	不计线上综合分
复赛	1,500	297,282	74,896	标签噪声 + 长尾	40%
半决赛	1,000	180,274	49,857	标签噪声 + 长尾	60%
总决赛	后续通知	后续通知	客观复核	线下答辩 + 复现	以细则为准

初赛只是熟悉任务和晋级，不进入最终线上综合分；复赛与半决赛才共同决定线上综合成绩。赛道通知给出的时间是：2026 年 9 月中旬前开始复赛，10 月 10 日前开始半决赛，11 月中下旬计划举行全国总决赛，具体日期仍以赛道公告为准。[算法挑战赛道通知](#)

这个安排直接推翻了「把初赛最优模型交出去即可」的直觉。初赛的类别均衡校正、去噪比例、最佳分辨率和 SWA 窗口，最多是有价值的先验。到了复赛和半决赛，类别数、样本量、长尾程度和具体图片全部变化，旧阶段数据还明确禁止混入新阶段训练。队友真正需要的是重新构建缓存、重新估计噪声、重新做 seed 控制和重新绑定证据的能力。

3.3 项目第一阶段：从能跑到 76 分平台

项目早期路线围绕冻结 CLIP ViT-B/32 + LoRA 展开。attn-only LoRA 很快遇到容量上限，于是扩到 attention + MLP，配合 EMA、RandAugment 和更高分辨率。448 像素让 ViT-B/32 从 7×7 的 49 个 patch token 增长到 14×14 的 196 个 token，对细粒度辨别帮助明显。

随后，项目建立了 kNN 一致性去噪、教师头共识伪标签、连续样本权重和严格 90/10 分层验证协议。重要的不只是这些组件本身，而是顺序：先划分训练/验证，再在训练分区内做所有标签驱动统计，验证样本只查询训练图库。这避免了一个常见的竞赛错觉——本地指标因为标签统计穿透验证集而变得漂亮，实际上并不能复现。

这一阶段把线上成绩推到约 76.1，但也暴露了第一个大陷阱：mid_03_06 和 noisy_all 是在脏标签上测的，本地越高不一定线上越好。长训练会逐渐记住脏验证标签，本地数字继续上涨，干净榜分却下降。此后团队形成了「本地指标负责筛错，线上榜分负责定方向」的纪律。

3.4 第二阶段：cleanlab、mixup 和同轨迹 SWA

真正突破 76.1 平台的是 cleanlab 式的标签质量估计。Confident Learning 不是简单地按模型最大概率删样本，它试图估计 noisy label 与潜在真实标签的联合分布，用类别相关阈值识别标签错误。[Confident Learning 论文](#) 项目中的 cleanlab 方案把单模型推到约 76.61，叠加 mixup 0.2 后，clmix 达到 77.13。

再往上不是继续堆复杂结构，而是沿同一次训练轨迹做权重平均。clmixsoup5 把 epoch 3 到 12 的十个 checkpoint 做 SWA，达到 78.6318。窗口实验呈现出很清楚的弧线：7 点 78.26，8 点 78.42，9 点 78.59，10 点 78.63；再加入更早的 warmup epoch，11 点和 12 点反而回落。

这里最值得交给队友的不是「十点最好」，而是背后的边界：相邻 epoch 位于同一收敛盆地，权重平均能降方差；跨 seed、跨配方的模型不再 mode-connected，平均后可能灾难性下降。项目里 cl2soup 只有 73.96，cl4soup 甚至掉到 70.65。SWA 是单模型权重空间中的一条窄桥，不是多模型结果随便倒进一口锅。

WiSE-FT 的研究也提醒了同一个方向：在预训练模型微调中，权重空间插值可以兼顾目标域精度与分布外鲁棒性。[WiSE-FT 论文](#) 不过本赛题禁止多模型集成，实际使用时必须把最终提交保持为单一模型、单一推理流程，并保留足以说明其合规性的构建过程。

3.5 第三阶段：推理杠杆和打榜系统的成熟

项目线上最大「免费增益」来自两个推理杠杆。

第一个是多尺度 TTA：448、512、576 加水水平翻转，约带来 1.1 分。它没有训练新模型，只让同一个模型从不同缩放视角观察测试图。

第二个是类别均衡 bias 校正。初赛官方测试集类别均衡，项目把预测类别分布拉回均匀，稳定带来约 2.9 分。clmixsoup3 的 balanced 版本是 78.59，无均衡 _tta 只有 75.46。历史上曾经把一批无均衡版本重复入队，连续浪费约 30 发；这个事故让「文件名后缀也是实验变量」变成了工程铁律。

另一个更严重的事故来自平台语义。AIC 公开榜展示的是团队最近一次已发布提交，不保存每个候选的完整历史最高。同一小时连发会让后面的低价值候选覆盖前面的展示项。旧系统又曾把平台 accepted 当作完整 done，导致高价值发没有抓到分就继续推进。

自动打榜机后来被重构为带 active lock 的状态机：queued、uploading、accepted、awaiting_score、scored、score_missed、failed、paused、skipped 各有明确含义；accepted 不再等于完成；一个小时只允许一个 effective submission；抓分证据必须绑定 queue index、accepted time、logical submission ID 和 candidate SHA-256。每个榜单发布窗口还使用一次性持久 claim，防止崩溃后重复抓同一窗口。

这一演进很有代表性。项目早期把自动化当节省点击的脚本，后来才发现它其实是一个金融交易式的幂等系统：每个外部动作都要有身份、锁、证据和恢复语义。自动化真正的价值不是更快，而是减少不可逆错误。

3.6 第四阶段：位置编码重采样把上限推到 78.91

在训练配方逐渐见顶后，项目回到一个很容易被忽略的细节：CLIP ViT-B/32 原生输入是 224，位置编码网格是 7×7。输入升到 448 或 512 时，位置编码也要被插值。

默认 timm 路线使用 bicubic 与 antialias。项目新增 aligned 路线，采用 bilinear + align_corners=True。最初的假设是 416 对应 13×13，原 7×7 锚点可以精确落在新网格的偶数节点上，因此奇数网格应更强。实验后来修正了这个故事：416 的纯增益只有 +0.036，448 是 +0.120，512 则是 +0.3765；真正稳定的现象不是奇偶网格，而是分辨率越高，插值方法越重要。

结果矩阵里，512 aligned 达到 78.9122，480 aligned 的 seed 123 达到 78.9082；但同一 480 配方 seed 42 只有 78.7439，相差 0.1643。这个 seed 对照杀死了「偶数网格天然更强」的漂亮叙事，也把最终判断改成更稳健的一句：448 到 576 是带噪的平台区，aligned 让高分辨率退化更慢，实际运营点应落在 448–512，而不是迷信某个像素值。

这是整个项目最有价值的研究习惯之一：先允许自己有机制假设，再用对照把故事推翻。结论经得住反例，比一次 78.91 更重要。

3.7 第五阶段：后续创新大多证明「复杂不等于更强」

位置编码之后，项目又尝试了保守 SSL 回收、双池化门控、动态划分、posterior soft divide、DivideMix、ELR、TrustCLIP 风格梯度投影、FET、DoRA、SCE、APL、OT、relabel、curriculum 和多种特征融合。

结果非常一致：保守 SSL 回收只有 78.5437，训练时间却大幅增加；双池化门控降到 78.2433；DivideMix 约 74.53；大多数头部结构和鲁棒损失没有超过简单 cleanlab + mixup + 同轨迹 SWA。

DivideMix 在论文里把样本损失分布建模成混合模型，把数据动态分为干净与噪声子集，再用两个网络互相提供划分并进行半监督学习。[DivideMix 论文](#) 它在标准 noisy-label benchmark 上很强，但赛事约束是单一模型流程，且本项目的细粒度 hard-but-correct 样本很多。激进划分会把真正困难的正确样本当噪声丢掉，论文机制与具体数据分布之间出现了错位。

JoAPR 则主张联合自适应阈值分区和标签修复，专门提升视觉语言模型 prompt learning 对标签噪声的鲁棒性。[JoAPR 论文](#) TrustCLIP 的题目进一步提出语义标签验证与 trust-aligned gradient projection，已被 ACM Multimedia 2025 接收。[ACM MM 2025 接收列表](#) 这些方法适合继续读，但项目现有结果已经给出约束：凡是需要额外模型、类语义文本、跨网络协同或激进分区的机制，都必须先检查赛事允许性和本数据的 hard-sample 结构，不能只因为论文新就烧算力。

四、横向分析：四种交接方式，谁适合这个项目

4.1 直接把整个目录压缩发过去

看起来最省事，实际上最差。当前工作目录混合了源码、数据缓存、数十 GB checkpoint、远程结果包、浏览器/提交日志和大量未提交改动。Git 对象库本身已有约 4.54 GiB 松散对象，直接压缩会把历史噪声、个人绝对路径和潜在凭据一起带走。队友收到后也不知道哪个文件是权威版本。

它唯一适合的场景是紧急灾备，而且必须在加密磁盘或可信局域网里传，不能当协作方式。

4.2 继续使用现有公开 GitHub 仓库

它的优点是已有 117 个提交，队友可以立即 clone；缺点是仓库公开，且 README 仍停留在早期 448 配方，和后来的 aligned、控制面、安全状态机已经分叉。更严重的是，比赛规则明确赛事数据仅限本次比赛使用，公开仓很容易让人无意提交数据、预测或状态证据。

GitHub 普通仓库会阻止超过 100 MiB 的文件，并建议仓库理想上小于 1 GB、强烈建议小于 5 GB。[GitHub 大文件说明](#) 750 MB checkpoint 无法进入普通 Git。继续沿用这个公开远端，会同时遇到合规、体积和版本可信度三个问题。

4.3 新建私有仓库，使用 Git LFS

Git LFS 把大文件内容放到独立对象存储，Git 历史里只保留指针。GitHub Free/Pro 的 LFS 单文件上限为 2 GB，750 MB checkpoint 在技术上可行。[Git LFS 说明](#)

优点是模型版本和代码 commit 可以一一对应，队友 clone 后能按指针下载；缺点是存储与带宽会计费或受配额影响，多个 750 MB checkpoint 很快膨胀。没有安装 Git LFS 的协作者只能得到指针文件，也容易误以为模型已经下载。

如果团队要持续比较多个阶段模型，LFS 适合只保留「每阶段一个基准 + 一个候选」。不要把每个 epoch 都放进去。

4.4 私有仓库 + GitHub Release 资产

Release 适合把一个确定的 checkpoint 当交付版本发布。GitHub 允许每个 Release 资产小于 2 GiB，单个 Release 最多 1000 个资产，并声明 Release 总大小和带宽没有总限制。[GitHub Releases 说明](#)

它比 LFS 更适合当前的一次性交接：代码仓保持轻量，`v0-initial-handoff` Release 里放 `full.pt`、预测 ZIP、资产清单和报告 PDF。队友看到 tag 就知道代码与模型的对应关系。缺点是模型更新不像 Git LFS 那样透明，需要手动下载或脚本拉取。

对当前团队，我更推荐 Release。到了复赛，如果每天都产生大模型版本，再评估是否迁移到 LFS 或对象存储。

4.5 最终选择

方案	存储成本	协作便利	版本控制	带宽/速度	风险/备注
整目录压缩	低	能	高	高	只做灾备
现公开仓	中	不能	很高	低	停止扩展
私有仓 + LFS	高	能	低	中	适合长期多版本
私有仓 + Release	高	能	低	低	本次交接首选

私有个人仓的协作者默认拥有读写权限，若团队需要更细粒度的只读/写入角色，应使用 GitHub Organization。[GitHub 私有仓权限说明](#)

五、交给队友的「精华」到底是什么

5.1 第一层：决策压缩

队友最需要的是一页决策图，而不是 151 条提交记录。

有效主线：CLIP ViT-B/32 冻结骨干 → attn+MLP LoRA → cleanlab → mixup 0.2 →

EMA/RandAugment → aligned 位置编码 → 448-512 → 同轨迹 SWA → 多尺度 TTA → 按官方测试先验做谨慎校正。

已经证伪：跨 seed soup、跨配方 soup、激进 DivideMix、ELR 大权重、FET 复杂头、DoRA、SCE/APL、relabel、OT、curriculum、双池化门控。它们不是永远无效，而是在初赛数据和现有实现下没有赢过基线；复赛重启时最多保留为二级候选，不能抢占基准复现时间。

5.2 第二层：一个能跑的参考模型

b448_aligned formal v2 是交付锚点，因为它有完整证据。它未必是历史单点最高，但比一个找不到 checkpoint 的 78.9122 更有工程价值。

队友拿到后先做三件事：校验 checkpoint SHA-256；用固定提交 ZIP 验证格式；在隔离 work-dir 做一次推理复核。任何一步不一致都停止，不要通过重新下载未知同名文件来猜。

5.3 第三层：实验账本，而不是日志墓地

完整 submissions/aicomp_results.csv 包含合法结果、重复提交、无均衡变体和违规探针。直接发过去会让新接手者把 92.0014 当冠军。交接包里的 SCORECARD.csv 只保留代表性节点，并为每条加上 legal / invalid_probe / offline_unsubmitted 状态。

原始账本仍应在私有归档中保留，因为它是证据；日常决策只看压缩后的 scorecard。

5.4 第四层：自动打榜的安全机制

真正要传的是这些机制：

- provenance 先于入队；
- exact intent 绑定候选与队列 revision；
- active lock 阻止同小时覆盖；
- submit-once 与 capture-only 分开；
- 抓分证据绑定 accepted time 与 candidate hash；
- 一次性窗口 claim 防止重复抓榜；
- task watcher 负责长时间等待，不在聊天里高频轮询；
- 未知状态 fail closed，不自动重提。

浏览器 cookies、个人 Chrome profile 和现有队列 JSON 反而不应该传。

5.5 第五层：负结果的边界

负结果不是废物。它们告诉队友在哪里别重复交学费，但必须写清条件。例如：「DivideMix 失败」的完整表述应是：初赛数据、当前实现、冻结 ViT-B/32、已有 cleanlab 先验下，动态划分把约 44% 训练分区降为 noisy/drop，线上约 74.53，显著低于 78.6 基线；不是说 DivideMix 论文在所有 noisy-label 任务上无效。

这种条件化表达也会直接改善总决赛答辩。评委问为什么不用更复杂方法时，团队可以拿出对照和机制解释，而不是说「试过，没用」。

六、接手后的前 72 小时

第 0–4 小时：建立信任链

队友创建私有仓库、clone 核心包、校验 `MANIFEST.sha256.csv`，再单独下载 `full.pt` 并校验 `8a349c...d0c73a`。运行 `compileall`、无 GPU 单测和提交 ZIP 校验。此阶段不训练、不提交。

第 4–12 小时：复现推理

用同阶段测试数据和固定 checkpoint 跑 448/512/576 + flip TTA，确认输出行数、文件名集合、预测分布和固定提交包一致。若完全一致，说明环境、模型加载、位置编码和后处理链路可信。

第 12–24 小时：复现训练烟测

在小样本或 `--smoke` 模式下验证 `cleanlab`、LoRA 注入、EMA、mixup、checkpoint 保存和 `provenance`。正式训练前先检查数据阶段标识，防止初赛缓存穿到新阶段。

第 24–48 小时：部署只读打榜

启动专用 Chrome，让队友自行登录。控制面只做 `queue_status`、候选 ZIP 校验和只读 `leaderboard` 页面检查，不执行真实提交。确认 `contract v4`、`queue schema 3`、`helper hash`、Node 路径和 CDP endpoint。

第 48–72 小时：第一发受控提交

由队长明确指定候选，生成 `provenance`，入队，读取 `exact intent`，再授权一次真实提交。随后只挂 `watcher`。抓到强绑定分数证据后复盘一次，确认队友真正理解 `accepted` 与 `scored` 的区别。

七、复赛与半决赛策略：哪些初赛结论可带走

可以直接带走

- 骨干与合规边界。
- 先划分再做标签统计的验证纪律。
- `cleanlab` + `mixup` + EMA 的基准价值。
- 同轨迹 SWA 的构建原则。
- `aligned` 位置编码作为高分辨率对照。
- `provenance`、`hash`、队列锁和一次性抓分 `claim`。

必须重新验证

- 448 与 512 的最优点。
- `keep ratio` 和 `cleanlab` 阈值。
- 训练轮数与 SWA 起点。

- balanced 校正。初赛测试集官方明确均衡，复赛/半决赛虽然评测规则仍是 Accuracy，但长尾描述主要指训练数据；不能自动假定测试分布和初赛完全相同。
- TTA 尺度。测试图原始分辨率可能变化。
- 本地验证代理。类别更多、长尾更强后，旧 mid_03_06 分带未必仍有筛选价值。

应新增的对照

1. 至少两个 seed 的 448/512 aligned 基线。
2. 训练期 class-aware sampler、logit adjustment 与普通采样对照。
3. 每类噪声率与样本数的二维分析，避免把尾部类当噪声整体删掉。
4. 不同 SWA 窗口的权重距离或线性插值损失，先证明 mode connectivity 再平均。
5. 按类别频次分桶的 holdout 指标，替代单一 noisy accuracy。

八、纵横交汇：历史如何塑造了今天的竞争位置

项目今天最强的地方不是某个单模块，而是「约束感」。早期 30 发无均衡误投和同小时覆盖事故，让团队建立了外部动作的身份与锁；本地指标多次误导，让团队学会把 proxy 只当 proxy；位置编码奇偶假设被 seed 对照推翻，让团队不再过度解释单次榜分；违规 89/92 探针则把表示瓶颈定位在 ViT-B/32，同时明确划出正式路线边界。

这些历史共同塑造了当前的生态位：算法层面不追求最复杂，而追求最少但互补的机制；工程层面不追求最快提交，而追求一次提交的完整闭环；交接层面不追求文件最多，而追求每个结论都能找到模型、配置、hash 和榜分证据。

竞争对手如果只有一个高分 ZIP，到了复赛换数据就要重新摸索；如果只有论文方法，没有打榜控制面，也会在平台窗口和提交证据上丢分。本项目真正可以形成优势的是把研究循环压缩成标准动作：构建可比较候选，自动生成来源，安全提交，准确归分，把负结果写回策略库。

但今天的劣势也来自历史。主仓和控制仓都处于混合 dirty worktree；公开 README 仍停留在旧配方；最强 78.9122 的 checkpoint 没有在本地闭环；控制面存在硬编码路径、队伍 ID 和 helper hash。过去为了快速迭代保留的本地假设，现在成了队友接手的摩擦。

所以交接不是附加工作，而是下一阶段竞争力本身。把系统整理成私有、轻量、可验证的两仓或单体包，等于提前完成半决赛要求的一半。

九、三个未来剧本

最可能剧本：基准迁移成功，分数由数据适配决定

队友用 1-2 天完成环境和控制面复现。复赛新数据上，cleanlab + mixup + aligned 448/512 仍是强基准，但最佳阈值和 SWA 窗口变化。团队通过小矩阵快速找到 2-4 个候选，线上综合分主要取决于长尾处理和 seed 稳定性。

这个剧本下，交接包最大的价值是节省「重新相信系统」的时间。

最危险剧本：把初赛 78.91 当固定配方，过拟合旧阶段经验

队友直接套 512 aligned、均衡 bias 和旧 cleanlab 阈值，没有重建分布诊断；同时把公开仓里的旧 README 当权威。复赛长尾类被错误过滤，测试分布又与初赛先验不同，线上掉分。为了追分，团队恢复旧 watchdog 或连续提交，覆盖高价值窗口。

这个剧本的预警信号很清楚：新阶段开始后没有 seed 对照、没有 per-frequency 指标、没有新 provenance scope，却很快出现大量提交。

最乐观剧本：交接系统反过来提升研究速度

私有仓把代码、配置、候选和证据全部结构化；checkpoint 通过 Release 与 tag 绑定；队友专注运行与分析，你专注 A 赛或新的研究方向。自动打榜只处理经过门禁的候选，每个结果自动落到 scorecard。到了半决赛，技术报告、实验消融和可复现环境已经随开发同步形成，决赛不需要临时补材料。

这个剧本不是靠再加一个模型实现的，而是靠消除协作中的信息损耗。

十、最终行动清单

1. 新建私有仓库，不在当前公开 lihao 继续推竞赛交接内容。
2. 运行 `build_handoff.ps1`，得到白名单核心包与 SHA-256 manifest。
3. 以 `v0-initial-handoff` 为 tag 建私有 Release。
4. 上传 `b448_aligned formal v2 full.pt`、固定预测 ZIP、报告 PDF 和 `ARTIFACTS.csv`。
5. 邀请队友，要求先跑 `verify_handoff.ps1`。
6. 队友完成推理复核后，再部署自动打榜只读状态。
7. 第一发真实提交必须由你明确授权，并完整走 `provenance` → `queue` → `exact intent` → `watcher` → `scored`。
8. 复赛开始时新建 `competition scope` 和队列，不复用初赛 `active/claims`。
9. 把历史最高 78.9122 标为「合法历史峰值」，把 78.8561 标为「交付参考模型」，不混写。
10. 违规 89/92 探针只留在受限诊断归档，报告、PPT 和正式模型中全部排除。

十一、信息来源

- [AIC 官方赛题：面向噪声标签数据的细粒度图像识别鲁棒微调](#)，访问时间 2026-08-16。
- [第八届 AIC 算法挑战赛道通知](#)，访问时间 2026-08-16。
- [CLIP: Learning Transferable Visual Models From Natural Language Supervision](#)。
- [LoRA: Low-Rank Adaptation of Large Language Models](#)。
- [Confident Learning: Estimating Uncertainty in Dataset Labels](#)。
- [DivideMix: Learning with Noisy Labels as Semi-supervised Learning](#)。
- [Robust Fine-tuning of Zero-shot Models](#)。

- [JoAPR: Cleaning the Lens of Prompt Learning for Vision-Language Models](#)。
- [ACM Multimedia 2025 accepted regular papers](#)。
- [GitHub: About large files on GitHub](#)。
- [GitHub: About Git Large File Storage](#)。
- [GitHub: About releases](#)。
- [GitHub: Permission levels for a personal account repository](#)。
- 本地项目证据: submissions/aicomp_results.csv、submissions/aicomp_state.md、docs/■■■■■■■■.md、docs/CLAUDE_CODE_MEMORY_HANDOFF.md、remote_posembed_exp/RESULTS.md、runs/aic_b448_*, 核对时间 2026-08-16。

十二、方法论说明

本报告采用横纵分析法：纵轴追踪赛制、技术路线和工程系统从 2026 年 4 月至今的演进；横轴比较研究方法、交接渠道和大文件协作方案；最后在两条轴的交点上给出可执行的团队交接与后续比赛策略。